

CONSTRUCCIÓN DE UN PANEL LONGITUDINAL MULTI-COHORTE SABER 11 →
SABER PRO (2014–2025): INTEGRACIÓN, LIMPIEZA Y VALIDACIÓN REPRODUCIBLE
DE MICRODATOS DEL ICFES

INTEGRANTES:
ELÍAS JOSÉ PARRA ROYERO
MARÍA MÓNICA MURILLO RINCÓN

DOCENTE:
ENRIQUE J. DE LA HOZ DOMÍNGUEZ

FACULTAD DE INGENIERÍA
PROGRAMA DE INGENIERÍA INDUSTRIAL
UNIVERSIDAD DEL MAGDALENA
PROYECTO 1 · INTEGRACIÓN DE DATOS ICFES
SANTA MARTA, MAGDALENA
2026

1. Resumen

Se construyó una base de datos consolidada a nivel de estudiante que vincula los registros de Saber 11 (24 periodos, de 2014-1 a 2025-2) y Saber Pro (11 años efectivamente disponibles en DataICFES a la fecha de consulta, de 2014 a 2024) mediante un flujo de integración reproducible, escrito en R con `data.table` y parametrizado desde un único archivo de configuración (`config.yml`). La base final contiene 517 119 registros y 71 variables.

El cruce combinó dos estrategias complementarias: una llave estándar de seis variables, vigente en la mayor parte de la ventana temporal, y una llave reforzada de cinco variables, aplicada exclusivamente a 2023-2024 debido a una tasa anómala de faltantes en el código del colegio de terminación de Saber Pro para esos años. De los 517 119 registros vinculados, 453 433 (87,7 %) provienen de la llave reforzada y 63 686 (12,3 %) de la llave estándar.

El proceso incluye validaciones automáticas de rango de puntajes, de unicidad por estudiante, de consistencia temporal (Saber Pro estrictamente posterior a Saber 11) y de convención de nombres de variables, todas con capacidad de detener la ejecución (`fail-fast`) ante datos inesperados. La fase de validación identificó 1 912 registros (0,37 % de la base) con rezago implausible entre pruebas —todos con orden temporal invertido— y 0 casos de vinculación ambigua dentro de la llave reforzada. La matriz de cobertura de cohortes, generada automáticamente, permite distinguir la pérdida de vinculación estructural (truncamiento por la izquierda y censura por la derecha, inherentes a la ventana temporal) de la atribuible al procedimiento; su desglose completo se reporta en el entregable de validación.

2. Fuentes de datos

Los microdatos se obtuvieron de DataICFES (ICFES, s.f.), la plataforma oficial de acceso a microdatos del Instituto Colombiano para la Evaluación de la Educación. La Tabla 1 resume los periodos solicitados según `config.yml` frente a los periodos efectivamente leídos por el pipeline, según consta en `logs/ejecucion.log`.

Prueba	Ventana solicitada	Ventana efectivamente leída	Patrón de archivo
Saber 11	20141 a 20252	24 periodos (20141–20252), sin faltantes de archivo	Examen_Saber_11_AAAAP.txt
Saber Pro	2014 a 2025	11 años (2014–2024); 2025 no publicado en DataICFES a la fecha de consulta	Examen_Saber_Pro_Genericas_AAAA.txt

Tabla 1. Ventana de datos solicitada y ventana efectivamente disponible por prueba.

El acceso a los microdatos se solicitó y confirmó en DataICFES el 12 de agosto de 2026. A esa fecha, Saber Pro 2025 aún no estaba publicado, por lo que la ventana efectiva de la base es 2014-2024 para Saber Pro y 2014-2025 para Saber 11. Esta restricción se declara explícitamente en vez de asumirse como dato faltante, siguiendo el requisito de verificación previa de disponibilidad de microdatos.

Además de los archivos de resultados, se emplearon tres fuentes de metadatos, todas versionadas como archivos editables en `data/metadata/` para no incrustar equivalencias dentro del código:

- `diccionario_saber11.xlsx` y `diccionario_saberpro.xlsx`: diccionarios de homologación con las columnas `nombre_final`, `nombre_en_archivo`, `periodo_desde` y `periodo_hasta`, que permiten mapear variables cuyo nombre en archivo cambia entre periodos.
- `divipola.xlsx`: codificación oficial DANE de departamentos y municipios, usada para contrastar los códigos geográficos reportados por los estudiantes.

El pipeline valida estructuralmente ambos diccionarios de homologación al inicio de la ejecución (columnas requeridas presentes y no vacíos) y detiene la ejecución con un mensaje explícito si alguno de los archivos Excel quedó mal formado, en vez de continuar en silencio con una especificación incompleta.

3. Estrategia de integración

Los microdatos públicos del ICFES no comparten un identificador único directo entre Saber 11 y Saber Pro, por lo que la vinculación se construyó sobre una llave compuesta por variables demográficas y de contexto disponibles en ambas pruebas.

3.1 Llave de vinculación condicional por periodo

Se definieron dos llaves, seleccionadas automáticamente según el año real de presentación de Saber Pro (`config.yml`, sección `llave_cruce`):

- Llave estándar (6 variables): `estu_fechanacimiento`, `estu_genero`, `estu_tipodocumento`, `estu_cod_reside_mcpio`, `cole_cod_dane_establecimiento`, `fami_estratovivienda`. Vigente para todos los años fuera del rango 2023-2024.
- Llave reforzada (5 variables): `estu_fechanacimiento`, `estu_genero`, `estu_tipodocumento`, `fami_estratovivienda`, `estu_mcpio_presentacion`. Aplicada exclusivamente a los años 2023 y 2024.

La llave reforzada se justifica en un hallazgo de la fase de limpieza: el log de ejecución registra advertencias de variables faltantes en `Examen_Saber_Pro_Genericas_2023.txt` (`estu_coddane_cole_termino`) y en `Examen_Saber_Pro_Genericas_2024.txt` (`estu_tipodocumentosb11`, `estu_mcpio_reside`, `estu_depto_reside`, `estu_coddane_cole_termino`). Usar la llave estándar —que depende del código DANE del colegio y del municipio de residencia— sobre esos dos años habría excluido sistemáticamente a los estudiantes con esos campos vacíos, introduciendo un sesgo de selección correlacionado con el año de presentación en lugar de reflejar una tasa de vinculación real. La contrapartida de usar una variable menos de

refuerzo es una llave teóricamente más permisiva; este riesgo se controló verificando vinculación ambigua exclusivamente sobre el subconjunto de la llave reforzada (sección 5), donde se documentaron 0 casos.

3.2 Tipo de unión y criterio de inclusión

Se aplicó una unión interna (merge con `all = FALSE`): solo se conservan estudiantes con coincidencia exacta en la llave correspondiente en ambas pruebas. Esta decisión es consistente con el objetivo del proyecto —un panel de trayectorias efectivamente observadas, no una imputación de trayectorias no observadas—. Antes de ejecutar cualquier unión, se excluyen los registros con NA en alguna variable de la llave aplicable a su periodo; este filtro se aplica en ambas bases y antes del merge, precisamente para evitar que `data.table` agrupe `NA == NA` como una coincidencia válida, lo que habría fusionado estudiantes distintos que simplemente comparten un campo vacío.

3.3 Reglas de consistencia temporal

- El periodo de Saber Pro se reexpresa como año real (`anio_saberpro = periodo %/% 10`), corrigiendo un supuesto inicial erróneo de que el campo periodo de Saber Pro era ya un año de 4 dígitos, cuando en realidad sigue el mismo código AAAAS de 5 dígitos que Saber 11.
- Se deriva `rezago_anios = anio_saberpro - anio_saber11` como variable de control de calidad del cruce.
- Se marca `rezago_implausible` cuando `rezago_anios < 0` (orden invertido) o excede un umbral calculado empíricamente como el percentil 99 de la distribución real de rezagos no negativos (9 años), en lugar de fijar un número arbitrario a priori.

3.4 Presentaciones múltiples y duplicados

Un estudiante puede presentar cualquiera de las dos pruebas más de una vez (reingresos, repitencia). La regla aplicada fue conservar la primera presentación cronológica de cada prueba (`order(periodo), .SD[1]`), agrupando por la identidad completa del estudiante. En Saber Pro, el agrupamiento se reforzó con `estu_mcpio_presentacion` y `estu_inst_municipio`, además de las variables demográficas base, porque agrupar solo con variables con alta tasa de NA fusionaba por error estudiantes distintos (se documenta el hallazgo y la corrección en la sección 4 y en la bitácora de decisiones).

3.5 Códigos institucionales como llave autoritativa

Se conservaron tanto el nombre del colegio o institución (normalizado en mayúsculas, sin tildes) como su código oficial DANE o SNIES, pero todo cruce y toda deduplicación se construyeron exclusivamente sobre los códigos: los nombres son una etiqueta legible para el usuario final de la base, no un criterio de identidad.

3.6 Diagrama del flujo de datos




Figura 1. Flujo de integración, desde los microdatos crudos hasta la base consolidada y el diccionario final. Las líneas discontinuas indican que cada etapa deja constancia en el registro de ejecución (logs/ejecucion.log).

4. Limpieza y estandarización

4.1 Tipificación de fechas y códigos geográficos

Las fechas de nacimiento, capturadas como texto en formato dd/mm/aaaa, se convirtieron a `IDate`. Los códigos DANE de municipio y departamento se rellenaron con ceros a la izquierda hasta su longitud oficial (`sprintf("%05d", ...)` y `"%02d"`) para no perder información al leerlos como enteros.

4.2 Valores centinela

Se identificaron y trataron como NA explícito varios valores centinela que no representan información real: la fecha 1900-01-01 (demográficamente imposible, implicaría más de cien años de edad) y 1980-01-31 (un pico aislado 10 veces superior al promedio de fechas vecinas, patrón típico de un valor por defecto del sistema, no de date heaping normal). Por separado, se documentó y se decidió no anular el date heaping propio de Saber 11 (concentración en fechas día = mes, como 09-09 o 12-12), por ser un patrón conocido de datos autorreportados y no una imposibilidad demográfica; se dejó como limitación de precisión, no como error de captura.

También se trataron como centinela: "Sin Estrato" (sin información socioeconómica real) y "Estrato 0" en Saber Pro 2016-2017 (n = 1 726), este último sin respaldo en la estratificación oficial colombiana (rango 1-6) y sin documentación del ICFES que lo defina como categoría válida; la decisión se tomó por ausencia de evidencia en contra, y se documenta expresamente como límite de certeza en la sección de limitaciones. El texto vacío en variables geográficas, de tipo de documento y de género se convirtió sistemáticamente a NA.

4.3 Distinción entre "no preguntado" y "no respondido"

Para las variables con cobertura parcial a lo largo de la serie, se generó una bandera *_motivo_na que compara el periodo del registro contra la ventana de vigencia declarada en el diccionario de homologación: si la variable no existía como pregunta en ese periodo, se marca "no_preguntado"; si existía pero el estudiante dejó el campo vacío, se marca "no_respondido". Esta lógica se aplicó explícitamente sobre percentil_global (Saber 11) y estu_tipodocumentosb11 (Saber Pro), y de forma sistemática sobre el resto de variables con cobertura parcial detectadas automáticamente en la fase de validación.

4.4 Normalización de texto

Los nombres de institución y de colegio se normalizaron a mayúsculas, sin espacios múltiples ni espacios al inicio/final, y sin tildes ni diacríticos (iconv con transliteración ASCII), para que la misma institución no se contara como distinta solo por diferencias de formato de captura.

4.5 Corrección crítica: periodo de Saber Pro como código, no como año

Durante la fase de diseño se detectó que el campo periodo de Saber Pro sigue el mismo código AAAAS de 5 dígitos que Saber 11 (por ejemplo 20233), y no un año simple de 4 dígitos como se había asumido inicialmente. Sin la corrección (anio_saberpro = periodo %/% 10), cualquier comparación de año —la partición de la llave reforzada 2023-2024 y el cálculo del rezago— producía resultados sin sentido. El error se detectó al verificar que, con el supuesto original, ningún registro caía dentro del rango esperado de la partición reforzada.

4.6 Comparabilidad de escala en Saber Pro

El ICFES modificó la escala de calificación de Saber Pro en el segundo periodo de 2016, de un rango aproximado de 0 a 20 a un rango de 0 a 300, de acuerdo con la Resolución 000455 de 2016

(ICFES, 2016), que establece que la línea de base de las nuevas escalas se construye a partir de la primera aplicación de 2016. El cambio se confirmó también de forma empírica, mediante un salto abrupto en el mínimo, el máximo y el promedio de los puntajes en el periodo 20162. Se descartó la existencia de una columna recalibrada alternativa en los años anteriores. Siguiendo el principio de no transformar sin sustento, se conservó el puntaje original sin modificarlo y se agregó la bandera derivada `puntaje_escala_comparable` (verdadera desde 20162 en adelante), de modo que cualquier análisis posterior filtre correctamente en vez de comparar puntajes en escalas distintas.

4.7 Validación contra la codificación DANE (DIVIPOLA)

Los códigos de municipio de residencia se contrastaron contra la tabla oficial DIVIPOLA. Se registraron 10 códigos no reconocidos en Saber 11 y 5 en Saber Pro (incluyendo NA y códigos como 99999, típicamente asociados a "extranjero" o "no aplica"), documentados como advertencia en el log sin detener la ejecución, dado que no invalidan el resto de la base.

4.8 Deduplicación: hallazgo y corrección

La primera versión de la deduplicación agrupaba únicamente por variables demográficas base. Esto generó una pérdida artificial de registros concentrada en 2023-2024 y en 2016-2 (entre 65 % y 84 % de caída), porque `data.table` trata `NA == NA` como una coincidencia válida al agrupar: estudiantes distintos sin colegio o sin municipio de residencia registrado se fusionaban entre sí por error. La corrección agregó `estu_mcpio_presentacion` y `estu_inst_municipio` —el mismo refuerzo ya usado para la llave de vinculación— al agrupamiento de deduplicación. Verificado el efecto, la caída en 2024 se redujo de un rango de 65-84 % a 13-29 %, consistente con el resto de la serie.

4.9 Validaciones fail-fast de rango

Los puntajes globales de ambas pruebas se validan contra los rangos teóricos declarados en `config.yml` (Saber 11: 0-500; Saber Pro: 0-300); la ejecución se detiene con un error explícito si algún valor cae fuera de rango, en vez de continuar con una base potencialmente corrupta.

5. Validación y calidad

La base final contiene 517 119 registros y 71 variables. La Tabla 2 resume su composición según la llave de cruce utilizada.

Llave utilizada	Registros vinculados	% del total
Estándar (6 variables, fuera de 2023-2024)	63 686	12,3 %
Reforzada (5 variables, 2023-2024)	453 433	87,7 %
Total	517 119	100 %

Tabla 2. Composición de la base final por llave de cruce.

Antes del cruce, se excluyeron por llave incompleta (NA en alguna variable) 1 379 584 registros de Saber 11 y 1 400 566 de Saber Pro bajo la llave estándar, y 1 075 267 de Saber 11 y 251 354 de Saber Pro bajo la llave reforzada. Este volumen es coherente con lo documentado en la sección 4: varias variables de la llave (código de colegio, municipio de residencia) presentan faltantes no triviales en ciertos años.

5.1 Unicidad y vinculación ambigua

Se verificó que la base final tuviera, dentro de cada tipo de llave, un registro por identidad de estudiante. Dentro de la llave reforzada —la única con un riesgo real de colisión al usar una variable menos de refuerzo— se identificaron 0 registros (0 %) con más de una coincidencia posible, es decir, vinculación ambigua nula en la corrida analizada.

5.2 Rezago entre pruebas

El umbral superior de plausibilidad del rezago se calculó como el percentil 99 de la distribución real de rezagos no negativos, resultando en 9 años, en lugar de fijarse a priori. Bajo este criterio, se marcaron 1 912 registros (0,37 % de la base) como rezago implausible, y la totalidad de esos casos corresponde a orden temporal invertido (rezago negativo): un Saber Pro fechado antes que el Saber 11 emparejado, indicio de falso positivo del cruce más que de una trayectoria educativa legítima pero atípica. Estos registros se dejan marcados mediante la variable `rezago_implausible`, no eliminados, para que cada análisis posterior decida si los excluye.

5.3 Matriz de cobertura de cohortes y sus tres regímenes

La matriz de cobertura (conteo de estudiantes emparejados por cada combinación de año de Saber 11 $\times$ año de Saber Pro) se genera automáticamente en cada corrida y constituye el entregable de validación central del proyecto. Su lectura correcta exige distinguir tres regímenes, tal como quedan registrados en el log de cada ejecución:

- Truncamiento por la izquierda: cohortes de Saber Pro tempranas cuyo Saber 11 correspondiente cae estructuralmente antes del inicio de la ventana disponible (2014). Su baja vinculación es esperada, no procedimental.
- Censura por la derecha: cohortes de Saber 11 recientes que, dentro de la ventana observada, aún no alcanzan su Saber Pro. Su baja vinculación también es estructural.
- Zona de observación plena: cohortes intermedias, donde ambas pruebas caen dentro de la ventana y la vinculación refleja mejor la tasa real de emparejamiento del procedimiento.

La matriz completa, con el desglose numérico por cohorte, se reporta íntegramente en el entregable de validación (reporte automático regenerado en cada ejecución), no se reproduce aquí para evitar duplicar un entregable que debe consultarse en su forma actualizada.

5.4 Tasa de vinculación por cohorte

La tasa de vinculación se calculó en ambos sentidos: por año de Saber 11 (denominador: total de presentantes de Saber 11 en el periodo) y por año de Saber Pro (denominador: total de presentantes de Saber Pro en el año, calculada para 11 cohortes). Ambas series, desagregadas, se reportan en el entregable de validación; el enunciado exige explícitamente no reportar solo una cifra global, y esta base cumple ese requisito al dejar ambas tasas desagregadas disponibles en cada corrida.

5.5 Faltantes por variable

El porcentaje de faltantes se calculó para las 71 variables de la base final y se reexpresa, para las variables con cobertura parcial detectada automáticamente, distinguiendo "no preguntado" de "no respondido" según la lógica descrita en la sección 4.3.

5.6 Validación geográfica

Como se describió en la sección 4.7, se registraron 10 códigos de municipio no reconocidos contra DIVIPOLA en Saber 11 y 5 en Saber Pro; su magnitud es marginal frente al tamaño de la base y no compromete la validez general del cruce.

5.7 Diccionario final

El diccionario de la base final documenta las 71 columnas con tipo de dato, porcentaje de faltantes y número de categorías únicas, calculados automáticamente en cada corrida sobre la base real (no sobre lo anotado manualmente en corridas anteriores). El contenido cualitativo —fuente, descripción, disponibilidad temporal y limitaciones de uso— se mantiene y edita a mano en `data/metadata/diccionario_base_final.xlsx`, y el pipeline advierte por log cuántas columnas quedan sin describir en cada corrida, para que ninguna quede documentada por omisión.

6. Reproducibilidad y automatización

El flujo se ejecuta con un único script maestro (`run_all.R`), que ordena las fases 00 a 07 (configuración, diccionarios de homologación, funciones de lectura, carga, limpieza, cruce, validación y diccionario final) y deja construido en memoria el objeto `base_cruzada`. La exportación final del `.csv` (`08_exportar.R`), que incluye su propia validación fail-fast de la convención de nombres de variable, se ejecuta como un paso explícito adicional; se recomienda incorporarla a `run_all.R` para que ejecutar ese único script sea, sin excepción, sinónimo de obtener el entregable final (ver limitaciones).

`run_all.R` incluye además un mecanismo de checkpoint (`FORZAR_RECARGA_COMPLETA`): cuando está en `FALSE` y existen los `.rds` de `saber11_completo/saberpro_completo` en `data/processed/`, el flujo omite la carga y limpieza completas y solo reejecuta el cruce, para iterar más rápido durante el desarrollo. Para la corrida de entrega, este parámetro debe quedar en `TRUE`, tal como está configurado en el script analizado, de modo que la base se reconstruya íntegramente desde los archivos crudos.

6.1 Parametrización

Todo parámetro temporal o de umbral vive en `config.yml`: las ventanas de años y periodos por prueba, el periodo de cambio de escala de Saber Pro, el periodo de vigencia de la llave reforzada, los rangos válidos de puntaje y las rutas de datos y metadatos. Para incorporar Saber Pro 2026 al reejecutar el próximo año, el `config.yml` documenta explícitamente el procedimiento: copiar el archivo nuevo a `data/raw/SaberPro`, actualizar `periodos.saberpro_hasta`, y volver a ejecutar `run_all.R` (y `08_exportar.R`). Ningún script en R/ requiere modificarse para ese caso.

6.2 Rutas relativas

Todos los scripts resuelven rutas mediante `here::here()`, lo que hace el proyecto autocontenido y portable entre equipos. El log de la última corrida analizada registra la escritura del `.csv` final en una ruta absoluta de OneDrive del equipo de trabajo; esa ruta es la resuelta dinámicamente por `here()` según dónde vive el proyecto en ese equipo, no una ruta escrita a mano dentro del código, pero conviene verificar antes de la entrega que la carpeta del proyecto se pueda clonar y ejecutar en una ubicación distinta sin ajustes.

6.3 Validaciones que detienen la ejecución

- Estructura de los diccionarios de homologación (columnas requeridas, no vacíos) — `01_diccionarios_homologacion.R`.
- Columnas de la llave de cruce ausentes en alguna de las dos bases — `05_cruce.R`.
- Puntajes globales fuera del rango teórico declarado en `config.yml` — `04_limpieza.R`.
- Nombres de variable que no cumplen la convención minúscula, sin tildes ni espacios — `08_exportar.R`.

6.4 Entorno declarado y semilla

La versión de R y de los paquetes utilizados se declara mediante la salida de `sessionInfo()`, guardada como parte del repositorio (ver `README.md` para el procedimiento de actualización). El pipeline no incluye ningún procedimiento con componente aleatorio (no hay muestreo ni simulación en ninguna de sus fases), por lo que no aplica fijar una semilla; se deja esta constancia explícita para que no se interprete como una omisión.

6.5 Registro de ejecución

`logs/ejecucion.log` acumula cada corrida con marca de tiempo, separando mensajes INFO de WARNING, y deja constancia de los archivos leídos, las variables faltantes por archivo, el tamaño de cada partición del cruce, los registros excluidos por llave incompleta y las advertencias de validación geográfica — la evidencia de trazabilidad exigida por el criterio de automatización.

7. Limitaciones

Esta sección documenta, de forma explícita y específica, lo que la base no resuelve y las precauciones que debe tomar quien la use para análisis posteriores.

- Ventana de Saber Pro efectivamente disponible (2014-2024, no 2025 como se había previsto en config.yml): cualquier análisis de la cohorte más reciente de Saber 11 (2024-2025) tendrá censura por la derecha adicional a la ya esperada por diseño.
- Comparabilidad de puntajes: el cambio de escala de Saber Pro en 2016-2 (Resolución 000455 de 2016) impide comparar directamente puntajes crudos anteriores y posteriores a ese corte. Se conservó el puntaje original sin transformarlo y se agregó la bandera `puntaje_escala_comparable`; cualquier análisis de tendencia de largo plazo debe filtrar por esta bandera o normalizar dentro de cada régimen de escala por separado.
- Llave reforzada con una variable menos de refuerzo (2023-2024): aunque la vinculación ambigua medida fue 0 %, la llave reforzada es intrínsecamente más permisiva que la estándar; el método de conteo de duplicados de llave usado no puede descartar una tasa baja de falsos positivos no detectables por esa vía.
- Rezago implausible (0,37 % de la base, 1 912 registros): se dejan marcados, no eliminados, por decisión metodológica explícita; quien requiera un panel longitudinal estrictamente ordenado en el tiempo debe decidir si los excluye.
- Códigos DANE no reconocidos contra DIVIPOLA (10 en Saber 11, 5 en Saber Pro): probablemente corresponden en su mayoría a estudiantes en el exterior o a valores "no aplica" (99999), pero no se investigó el origen de cada código individualmente por restricción de tiempo; se documenta como limitación conocida en vez de descartarse en silencio.
- El diccionario final se documenta automáticamente en sus hechos técnicos (tipo de dato, % de faltantes, categorías únicas), pero el contenido cualitativo de las descripciones se completa y mantiene a mano; su exactitud no es verificable por código.
- `08_exportar.R` no forma parte de la cadena de `source()` de `run_all.R`: la exportación final, con su propia validación de convención de nombres, se ejecuta como paso adicional explícito. Se recomienda incorporarlo a `run_all.R` para que ejecutar ese único script sea, sin excepción, sinónimo de obtener el .csv final.
- No se cuantificó de forma independiente el efecto sobre la tasa de colisión de la llave de los aproximadamente 29 682 casos de `estu_tipodocumentosb11` vacío detectados en 2014 (decreciendo en años posteriores); se documentó como limitación real de la llave de vinculación para esos estudiantes específicos, sin un análisis de sensibilidad adicional.

8. Uso de inteligencia artificial

Se utilizó Claude (Anthropic) como asistente durante las fases de diseño, limpieza, validación y automatización del proyecto, principalmente para depurar la lógica de partición de la llave reforzada por año real, diagnosticar la caída artificial de registros en la deduplicación de 2023-2024, calcular de forma empírica el umbral de rezago plausible, y redactar y verificar la

interpretación textual de la matriz de cobertura de cohortes. Cada sugerencia se verificó contra el log de ejecución y contra conteos reales de la base antes de aceptarse.

Un caso representativo de error detectado y corregido: al diseñar la partición de la llave reforzada, el modelo propuso inicialmente comparar el campo periodo de Saber Pro directamente contra los años 2023 y 2024 de config.yml, sin advertir que periodo es un código AAAAS de 5 dígitos y no un año de 4 dígitos. Bajo ese supuesto, la partición reforzada habría quedado vacía. El error se detectó al verificar que ningún registro caía en el rango esperado, y se corrigió agregando la variable derivada `anio_saberpro = periodo %/% 10`. El detalle completo de esta y otras interacciones, su verificación y su resultado se documentan en docs/bitacora_ia.md, entregable anexo obligatorio.

Referencias

Instituto Colombiano para la Evaluación de la Educación [ICFES]. (2016). Resolución 000455 de 2016. <https://www.icfes.gov.co>

Instituto Colombiano para la Evaluación de la Educación [ICFES]. (s.f.). DataICFES. Recuperado el 12 de agosto de 2026, de <https://www.icfes.gov.co/investigaciones/data-icfes/>

R Core Team. (2024). R: A language and environment for statistical computing. R Foundation for Statistical Computing. <https://www.R-project.org/>

Dowle, M., & Srinivasan, A. (2024). data.table: Extension of `data.frame` (versión R). <https://CRAN.R-project.org/package=data.table>